

Inteligência Artificial Aplicada na Análise da Desigualdade Econômica e Pobreza Global

Guilherme Henrique de Souza Sonsin¹, João Victor da Silva Pires², Ricardo Henrique Vinciguerra³, Steffany Kazik Sarmento Bassi⁴

¹Centro Universitário Assis Gurgacz
Toledo – PR – Brasil

²Centro Universitário Assis Gurgacz
Toledo – PR – Brasil

³Centro Universitário Assis Gurgacz
Toledo – PR – Brasil

⁴Centro Universitário Assis Gurgacz
Toledo – PR – Brasil

ghdssonsin@minha.fag.edu.br, jvdspires@minha.fag.edu.br,

rhvinciguerra@minha.fag.edu.br, sksbassi@minha.fag.com.br

Abstract. Poverty and economic inequality remain among the greatest challenges faced by modern societies. With the increasing availability of socioeconomic data and advances in Artificial Intelligence, Machine Learning techniques can be used to identify patterns and generate predictions related to social indicators. This work presents the application of Machine Learning techniques to the Global Poverty and Economic Inequality (2015–2024) dataset available on Kaggle. The study involved data collection, preprocessing, exploratory analysis, modeling, and evaluation phases in order to understand the relationships between economic indicators and poverty levels worldwide. The results demonstrate that the applied algorithms are capable of identifying relevant patterns and supporting the understanding of factors associated with economic inequality.

Resumo. A pobreza e a desigualdade econômica permanecem entre os principais desafios enfrentados pela sociedade contemporânea. Com o crescimento da disponibilidade de dados socioeconômicos e o avanço das técnicas de Inteligência Artificial, tornou-se possível utilizar algoritmos de Machine Learning para identificar padrões e realizar previsões relacionadas a indicadores sociais. Este trabalho apresenta a aplicação de técnicas de aprendizado de máquina sobre a base de dados “Global Poverty and Economic Inequality (2015–2024)”, disponibilizada na plataforma Kaggle. O estudo envolveu etapas de coleta, tratamento, análise exploratória, modelagem e avaliação dos dados, buscando compreender as relações existentes entre indicadores econômicos e os níveis de pobreza observados globalmente. Os resultados demonstram que os algoritmos aplicados são capazes de identificar padrões relevantes e auxiliar na compreensão dos fatores associados à desigualdade econômica.

1. Introdução

A pobreza e a desigualdade econômica são problemas históricos que afetam países em diferentes níveis de desenvolvimento. Apesar dos avanços tecnológicos e do crescimento econômico observados em diversas regiões do mundo nas últimas décadas, milhões de pessoas ainda vivem em condições de vulnerabilidade social, enfrentando dificuldades relacionadas ao acesso à educação, saúde, alimentação, moradia e oportunidades de emprego.

Segundo organismos internacionais como a Organização das Nações Unidas (ONU) e o Banco Mundial, a redução da pobreza extrema e das desigualdades sociais constitui um dos principais objetivos globais para o desenvolvimento sustentável. Entretanto, compreender os fatores que influenciam esses indicadores é uma tarefa complexa, especialmente devido à grande quantidade de variáveis econômicas, sociais e demográficas envolvidas.

Nesse contexto, a Inteligência Artificial e as técnicas de Machine Learning vêm sendo utilizadas para auxiliar pesquisadores, governos e instituições na análise de grandes volumes de dados. Essas técnicas permitem identificar padrões ocultos, realizar previsões e gerar informações relevantes para o desenvolvimento de políticas públicas mais eficientes.

Diante desse cenário, este trabalho tem como objetivo aplicar técnicas de aprendizado de máquina em uma base de dados global contendo indicadores de pobreza e desigualdade econômica referentes ao período de 2015 a 2024. Busca-se compreender as relações existentes entre os indicadores analisados e avaliar o potencial dos algoritmos de Machine Learning na geração de previsões socioeconômicas.

2. Fundamentação Teórica

2.1. Inteligência Artificial

A Inteligência Artificial é um ramo da ciência da computação que busca desenvolver sistemas capazes de executar atividades que normalmente exigem inteligência humana, como o reconhecimento de padrões, a tomada de decisão, o aprendizado e a resolução de problemas.

Segundo Russell e Norvig (2021), a Inteligência Artificial tornou-se uma das áreas mais relevantes da computação moderna, sendo aplicada em setores como saúde, finanças, educação, indústria e administração pública. Sua evolução está diretamente relacionada ao aumento da capacidade computacional e à disponibilidade de grandes volumes de dados.

2.2. Machine Learning

Machine Learning, ou aprendizado de máquina, é uma subárea da Inteligência Artificial que permite que sistemas computacionais aprendam padrões a partir de dados históricos sem a necessidade de programação explícita para cada situação.

Os algoritmos de aprendizado de máquina aborda os pontos:

- Aprendizado supervisionado;
- Aprendizado não supervisionado.

Neste trabalho foi utilizada a abordagem supervisionada, uma vez que o objetivo consiste em realizar previsões a partir de informações previamente conhecidas.

2.3. Pobreza e Desigualdade Econômica.

A pobreza é geralmente definida como a insuficiência de recursos necessários para garantir condições mínimas de sobrevivência e qualidade de vida. Já a desigualdade econômica refere-se à distribuição desigual da renda, riqueza e oportunidades entre indivíduos ou grupos sociais.

Diversos fatores podem influenciar esses indicadores, incluindo renda per capita, acesso à educação, condições de emprego, investimentos governamentais e desenvolvimento econômico. A análise desses fatores permite compreender melhor os mecanismos que contribuem para o aumento ou redução da pobreza em diferentes regiões do mundo.

3. Metodologia

3.1. Base de Dados

Para o desenvolvimento deste trabalho foi utilizada a base de dados denominada “Global Poverty and Economic Inequality (2015–2024)”, disponibilizada na plataforma Kaggle. O arquivo principal contém 10.000 registros referentes ao período de 2015 a 2024 e abrange 25 variáveis que descrevem indicadores socioeconômicos de diversos países do mundo, permitindo a realização de análises temporais e comparativas sobre pobreza e desigualdade econômica.

A obtenção dos dados foi realizada de forma automatizada por meio do site Kaggle, que permite o download direto do dataset dentro do ambiente de execução.

3.2. Ferramentas e tecnologias utilizadas

O projeto foi desenvolvido utilizando o ambiente Google Colab, uma plataforma baseada em nuvem amplamente utilizada em projetos de Ciência de Dados e Machine Learning.

As principais bibliotecas utilizadas foram:

- Pandas - Manipulação e análise de dados tabulares;
- NumPy - Operações numéricas e vetorizadas;
- Matplotlib - Criação de gráficos e visualizações;
- Seaborn - Visualizações estatísticas avançadas;
- Scikit-Learn - Aprendizado de máquina (modelos, pré-processamento, validação);
- KaggleHub - Download automatizado de datasets do Kaggle.

A linguagem de programação utilizada para o desenvolvimento foi a linguagem Python, devido à sua ampla adoção na comunidade científica e à disponibilidade de bibliotecas especializadas para análise de dados.

3.3. Pré -processamento de Dados

A etapa de pré-processamento teve como objetivo garantir a qualidade dos dados antes da aplicação dos algoritmos de aprendizado de máquina e foi realizado em três etapas principais: Renomeação de Variáveis, Padronização e Filtro Temporal e Diagnóstico de Dados Ausentes.

3.3.1 Renomeação de Variáveis

Todas as colunas do dataset foram renomeadas do inglês, linguagem que veio do dataset, para o português, utilizando um dicionário de mapeamento explícito, para facilitar a leitura e interpretação dos resultados. Ao todo, 25 colunas foram renomeadas com nomes descritivos em português.

3.3.2 Padronização e Filtro Temporal

Os dados foram filtrados para o período de 2015 a 2024. A coluna de ano foi convertida para tipo numérico, e as demais colunas quantitativas foram convertidas para tipos numéricos com tratamento de erros.

3.3.3 Diagnóstico de Dados Ausentes

Foi realizada uma verificação do percentual de dados ausentes por coluna. O dataset apresentou completude satisfatória, o que permitiu a utilização direta dos dados sem necessidade de imputação extensiva.

3.4. Análise Exploratória dos Dados

Após a preparação da base, foi realizada uma análise exploratória dos dados (EDA), buscando compreender a distribuição dos atributos e identificar possíveis correlações entre as variáveis, conduzida em múltiplas dimensões:

- Estatísticas descritivas: cálculo de média, desvio padrão, mínimo, máximo, quartis e contagem para todos os indicadores numéricos identificados;
- Tendências temporais: cálculo das médias anuais globais dos indicadores prioritários (taxa de pobreza, coeficiente de Gini, PIB per capita, taxa de desemprego e IDH) para o período 2015–2024, com visualização em gráficos;
- Comparação entre países: identificação dos 10 países com maiores e menores valores médios nos indicadores-chave (taxa de pobreza e coeficiente de Gini), utilizando gráficos de barras horizontais;

Essa etapa permitiu identificar tendências importantes e compreender o comportamento dos indicadores socioeconômicos presentes na base.

3.5. Técnicas de Aprendizado de Máquina

3.5.1 Aprendizado Não Supervisionado — K-Means

A clusterização K-Means foi utilizada para agrupar países com perfis socioeconômicos semelhantes, sem recorrer a classificações prévias. O procedimento consistiu nas seguintes etapas:

- Cálculo das médias por país para todas as variáveis numéricas identificadas;
- Padronização das features utilizando StandardScaler;
- Aplicação do algoritmo K-Means com $k=4$ clusters, $n_init=10$ e $random_state=42$;
- Visualização dos clusters em um gráfico de dispersão bidimensional utilizando PIB per capita e taxa de pobreza como eixos.

3.5.2 Aprendizado Supervisionado — Modelos de Regressão

Três modelos de regressão foram avaliados por validação cruzada (K-Fold com $k=5$) para duas variáveis-alvo: porcentagem da taxa de pobreza e coeficiente de Gini. Os modelos utilizados foram:

- Regressão Linear: modelo baseline que assume relações lineares entre features e variável-alvo.
- Random Forest Regressor: ensemble de árvores de decisão que captura relações não lineares e interações entre variáveis;
- Gradient Boosting Regressor: método de boosting sequencial que constrói modelos aditivos otimizando o erro residual a cada iteração.

As métricas de avaliação utilizadas foram o Erro Absoluto Médio (MAE), a Raiz do Erro Quadrático Médio (RMSE) e o Coeficiente de Determinação (R^2).

4. Resultados e Discussão

4.1 Análise Temporal dos Indicadores Socioeconômicos




Figura 01. Tendências Globais dos Indicadores Socioeconômicos (2015-2024)

Inicialmente foi realizada uma análise temporal dos principais indicadores socioeconômicos globais entre os anos de 2015 e 2024, conforme ilustrado na Figura 1.

Observou-se uma tendência geral de redução da taxa de pobreza ao longo do período analisado. Em 2015 a taxa média encontrava-se próxima de 25%, atingindo aproximadamente 21% em 2024. Embora tenham ocorrido pequenas oscilações durante o período, a tendência geral indica melhora nas condições socioeconômicas globais.

O Produto Interno Bruto (PIB) per capita apresentou crescimento consistente durante a década analisada. Os valores evoluíram de aproximadamente US\$ 11.400 para mais de US\$ 15.000 ao final do período. Esse crescimento econômico coincide com a redução observada nos índices de pobreza.

O Índice de Desenvolvimento Humano (IDH) também apresentou evolução positiva, passando de aproximadamente 0,643 para 0,670. Esse resultado demonstra avanços em fatores relacionados à educação, saúde e renda, componentes fundamentais para o desenvolvimento humano.

Em contrapartida, o Coeficiente de Gini apresentou poucas variações ao longo do período, mantendo-se próximo de 42 pontos. Esse comportamento sugere que, apesar da redução da pobreza e do aumento do PIB per capita, a distribuição da renda permaneceu relativamente estável.

A taxa de desemprego apresentou comportamento moderadamente estável durante toda a série histórica, oscilando entre aproximadamente 8,8% e 9,3%, sem apresentar tendência significativa de crescimento ou redução.

Os resultados sugerem que o crescimento econômico global contribuiu para a redução da pobreza, porém não foi suficiente para provocar alterações expressivas nos níveis de desigualdade econômica.

4.2 Comparação Entre Países




Figura 02. Comparação entre Países – Taxa de Pobreza e Coeficiente de Gini

Com o objetivo de identificar diferenças regionais, foram analisados os países que apresentaram os maiores e menores índices de pobreza e desigualdade econômica.

Os resultados demonstraram que países como Sudão, Tanzânia, Nepal, Etiópia e Mali apresentaram as maiores taxas de pobreza, todas superiores a 50%. Esses países compartilham características relacionadas a baixos níveis de desenvolvimento econômico, limitações estruturais e desafios históricos relacionados ao crescimento sustentável.

Por outro lado, países como Estados Unidos, Austrália, Japão, França e Coreia do Sul apresentaram os menores índices de pobreza, todos próximos ou inferiores a 1%.

Quando analisado o Coeficiente de Gini, observou-se que países como Turquia, Sudão, Indonésia, México e África do Sul apresentaram os maiores níveis de desigualdade econômica. Em contraste, Japão, Canadá, Reino Unido, Alemanha e França apresentaram os menores índices.

Um resultado interessante identificado durante a análise é que baixos índices de pobreza não necessariamente implicam baixos níveis de desigualdade econômica. Esse comportamento evidencia que crescimento econômico e distribuição de renda são fenômenos distintos e devem ser analisados separadamente.

4.3 Análise de Correlação




Figura 03. Matriz de Correlação – Indicadores Socioeconômicos

A matriz de correlação permitiu identificar relações estatisticamente relevantes entre os indicadores analisados.

A taxa de pobreza apresentou forte correlação negativa com o IDH (-0,81), indicando que países com maior desenvolvimento humano tendem a apresentar menores níveis de pobreza.

Também foi observada correlação negativa significativa entre pobreza e PIB per capita (-0,54), demonstrando que economias mais desenvolvidas tendem a apresentar menores índices de vulnerabilidade social.

Outro resultado relevante foi a forte correlação positiva entre pobreza e mortalidade infantil (0,84), evidenciando que regiões mais pobres tendem a enfrentar maiores dificuldades relacionadas à saúde pública e condições de vida.

A expectativa de vida apresentou correlação negativa de -0,82 com a pobreza, reforçando a relação entre desenvolvimento social e redução da vulnerabilidade econômica.

O IDH apresentou forte correlação positiva com expectativa de vida (0,89) e alfabetização (0,84), resultados compatíveis com a literatura econômica e social.

Esses achados demonstram que indicadores educacionais e de saúde possuem papel fundamental na redução da pobreza e na melhoria da qualidade de vida da população.

4.4 Agrupamento de Países Utilizando K-Means




Figura 04. Agrupamento K-Means de Países (k=4) PIB per Capita x Taxa de Pobreza

Além das análises preditivas, foi aplicada a técnica de aprendizado não supervisionado K-Means com quatro agrupamentos (k=4), utilizando como variáveis principais o PIB per capita e a taxa de pobreza. Sendo que os resultados permitiram identificar grupos socioeconômicos distintos.

O primeiro agrupamento concentrou países com elevada taxa de pobreza e baixo PIB per capita. Esse grupo representa economias em desenvolvimento que enfrentam desafios estruturais relacionados à geração de renda e redução das desigualdades sociais.

O segundo agrupamento reuniu países com níveis intermediários de pobreza e desenvolvimento econômico moderado.

O terceiro agrupamento destacou países com elevado PIB per capita e baixíssima taxa de pobreza, representando economias desenvolvidas com melhores indicadores sociais.

A capacidade do algoritmo em separar claramente esses grupos demonstra que as variáveis selecionadas possuem forte poder discriminatório para caracterizar diferentes níveis de desenvolvimento econômico e social.

Essa análise reforça o potencial das técnicas de clusterização para segmentação de países e identificação de perfis socioeconômicos semelhantes.

4.5 Avaliação dos Modelos de Machine Learning – Predição da Taxa de Pobreza




Figura 05. Desempenho dos Modelos – Taxa de Pobreza (%)

Para a predição da taxa de pobreza foram avaliados três algoritmos de regressão:

- Regressão Linear;
- Random Forest;
- Gradient Boosting.

Os resultados demonstraram que os modelos baseados em árvores apresentaram desempenho superior ao modelo linear.

Esses resultados apresentados na Figura 05 indicam que a relação entre os indicadores socioeconômicos e a taxa de pobreza apresenta comportamento não linear, favorecendo algoritmos capazes de capturar interações mais complexas entre as variáveis.

4.6 Avaliação dos Modelos de Machine Learning – Predição do Coeficiente de Gini




Figura 06. Desempenho dos Modelos - Coeficiente de Gini

Também foi realizada a previsão do Coeficiente de Gini utilizando os mesmos algoritmos. E, novamente os modelos baseados em árvores apresentaram melhor desempenho.

A Regressão Linear obteve coeficiente de determinação próximo de 0,30, demonstrando capacidade limitada de explicar a variabilidade da desigualdade econômica.

O Random Forest elevou o R^2 para aproximadamente 0,41, enquanto o Gradient Boosting apresentou o melhor resultado, alcançando aproximadamente 0,43.

Apesar da melhora observada, os valores de R^2 permaneceram inferiores aos obtidos na previsão da pobreza. Esse resultado sugere que a desigualdade econômica é influenciada por fatores mais complexos e de difícil modelagem, incluindo aspectos políticos, institucionais e culturais não presentes na base analisada.

5. Conclusão

Este trabalho apresentou a aplicação de técnicas de Machine Learning para análise da pobreza global e da desigualdade econômica utilizando dados referentes ao período de 2015 a 2024.

O desenvolvimento do projeto envolveu todas as etapas clássicas de um processo de Ciência de Dados, incluindo obtenção dos dados, preparação da base, análise exploratória, construção dos modelos preditivos e avaliação dos resultados.

Os resultados demonstraram que algoritmos de aprendizado supervisionado podem ser utilizados para identificar padrões relevantes e gerar previsões úteis para a compreensão de fenômenos socioeconômicos complexos.

Além de contribuir para o aprendizado dos conceitos relacionados à Inteligência Artificial, o trabalho evidenciou o potencial dessas técnicas para auxiliar pesquisadores, governos e organizações internacionais na análise de indicadores sociais e econômicos.

6. Referências

Google Acadêmico. Disponível em: <https://scholar.google.com.br/>. Acesso em: 28 de maio 2026.

LECUN, Yann; BENGIO, Yoshua; HINTON, Geoffrey. Aprendizagem profunda. Nature, v. 521, n. 7553, p. 436-444, 2015.

KAGGLE. Global Poverty and Economic Inequality (2015–2024). Disponível em: <https://www.kaggle.com/datasets/hamnamunir/global-poverty-and-economic-inequality-2015-2024>. Acesso em: 28 de maio 2026.

PEDREGOSA, Fabian et al. Scikit-learn: Machine learning in Python. the Journal of machine Learning research, v. 12, p. 2825-2830, 2011.

RUSSELL, Stuart J. Inteligência artificial: uma abordagem moderna. Pearson Education, Inc., 2010.